Sistemas de Memória

Computador: Máquina programável, de propósito geral, que processa informação.

Programa: Sequência de instruções (de uma dada linguagem de programação) que operam sobre dados, realizando um processamento de informação específico.

Instrução: Operação que realiza algum processamento básico de informação. Exemplo: somar dois números, armazenar um dado, etc.

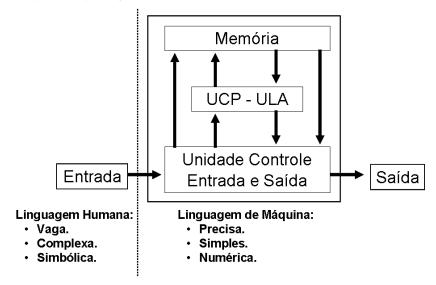
Linguagem - Linguagem de Programação: Conjunto de instruções associadas a uma sintaxe e uma semântica específicas.

Hardware: Composto por objetos tangíveis (parte física) - circuitos integrados, placas de circuito impresso, cabos, fontes de alimentação, memórias, impressoras, etc.

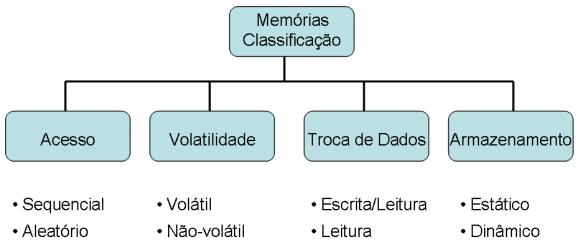
Software: É composto de instruções, algoritmos e por suas representações computacionais - os programas.

Hardware e Software são logicamente equivalentes.

Firmware: Software embarcado - trata-se de um software que controla o hardware diretamente. Ex.: BIOS - Basic Input/Output System.



Classificação de Memórias



Acesso

As memórias acessam informações em lugares denominados localidades de memória. Cada uma das localidades de memória possui um conjunto de bits que nos permite o seu acesso. A este conjunto de bits dá-se o nome de endereço. Esse conceito é de fácil compreensão, pois

como o próprio nome diz, o conjunto de bits representa o endereço da localidade onde está armazenada uma informação.

O tempo de acesso de uma memória é o tempo necessário desde a entrada de um endereço até o momento que a informação apareça na saída. Para as memórias de escrita/leitura é também o tempo necessário para a informação ser gravada.

Pode-se ter acesso a uma dada localidade de memória de dois modos: Acesso Sequencial e Acesso Aleatório:

- As memórias que utilizam o acesso sequencial, dado o endereço de certa localidade, permitem que se chegue até esta, passando por todas as localidades intermediárias. Nas memórias mais comuns este tipo de acesso são as que operam com fitas magnéticas, sendo utilizadas com memória de massa em computadores (para grande quantidade de dados).
- As memórias que utilizam o acesso aleatório, dado um endereço de uma certa localidade, permite que se chegue até esta diretamente, sem que se necessite passar pelas localidades intermediárias. As principais memórias com este tipo de acesso são também conhecidas como RAM (Random Access Memory). São largamente utilizadas em sistemas digitais programáveis. Possuem a grande vantagem de ter um tempo de acesso pequeno e igual para qualquer uma das localidades de memória. Analisaremos mais adiante o circuito da memória RAM.

Volatilidade

Quanto à volatilidade, as memórias podem ser voláteis ou não-voláteis.

- As memórias voláteis são aquelas que, ao ser cortado à alimentação (energia), perde as informações armazenadas. São memórias feitas, geralmente, a partir de semicondutores e na maioria das vezes, possuem como elemento de memória o flipflop. Um exemplo típico já citado é da memória RAM.
- As memórias não-voláteis são aquelas que mesmo sem alimentação, continuam com as informações armazenadas. Dentre essas se destacam as memórias magnéticas e as eletrônicas: ROM, PROM e EPROM e memórias de massa.

Troca de Dados

No que se refere à troca de dados com outros componentes do sistema, as memórias podem ser de escrita/leitura ou memória apenas de leitura.

- As memórias de escrita/leitura são aquelas que permitem acesso a uma localidade qualquer para armazenar a informação desejada, além disso, permitem o acesso também para a leitura do dado. As memórias RAM também se enquadram nesta situação, HD e pen drive.
- As memórias apenas de leitura, como o próprio nome diz, são aquelas em que a informação é fixa, só podendo efetuar-se a leitura. São também conhecidas como ROM (Read-Only Memory). Exemplo CD, DVD e Blu ray.

Tipos de Armazenamento

Quanto ao tipo de armazenamento, as memórias classificam-se: estáticas e dinâmicas.

- As memórias de armazenamento estático são aquelas em que uma vez inserido o dado numa dada localidade, este lá permanece.
- As memórias de armazenamento dinâmico são aquelas em que necessitam inserir a informação de tempos em tempos, pois de acordo com as características de seus elementos internos, perdem essas informações após um determinado tempo. As memórias de armazenamento estático apresentam a vantagem de possuir uma utilização de maneira mais fácil que dinâmicas.

Gerência de Memória

A memória é usada para armazenar os diversos programas em execução, bem como os dados sobre a execução dos programas, é constituída por conjuntos de vetores de palavras ou bytes, cada uma com endereço próprio.

O Sistema Operacional permite que os processos compartilhem a memória de forma segura e eficiente, usando os recursos disponíveis no hardware, na multiprogramação diversos

processos são colocados na memória ao mesmo tempo para que o chaveamento entre eles seja o mais rápido possível.

A Unidade de Gerência de Memória (MMU – Memory Management Unit): provê mecanismos de gerência de memória para o Sistema Operacional que converte e/ou mapeia endereços lógicos em físicos.

Memória Lógica e Física

Memória lógica: é aquela que o processo enxerga, ou seja, aquela que o processo é capaz de ter acesso. Os endereços manipulados pelo programa são lógicos e em geral capa processo possui uma memória lógica independente da memória lógica dos outros processos.

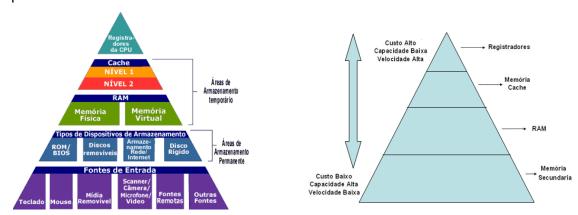
Memória física: é aquela que é efetivamente acessada pelo circuito integrado de memória. Dois processos podem ter espaços de endereçamento iguais que correspondem a áreas diferentes do espaço de endereçamento físico.

- Quando os endereços lógicos coincidem com os endereços físicos: Pode-se implementar proteção de memória usando dois registradores de limite, os endereços do programa são gerados a partir de 0 e devem ser ajustados por um carregador realocador durante a carga; relocação em tempo de carga.
- Quando os endereços lógicos não coincidem com os físicos: Pode-se trabalhar com um registrador de limite e outro de base, os endereços são gerados a partir de 0, mas não é necessária nenhuma alteração de endereço; o carregador é chamado de absoluto; relocação em tempo de execução.

O acesso aos registradores de limite e de base é feito através de instruções privilegiadas o conteúdo desses registradores faz parte do contexto do processo técnicas de gerência de memória: partições fixas; partições variáveis; swapping; paginação; segmentação e segmentação paginada.

Sistema de Memória é uma das principais partes do computador, juntamente com o processador. Todos os programas e seus dados são mantidos no Sistema de Memória e ele é responsável por entregar o mais rapidamente para o processador quando solicitado. Não é uma tarefa simples porque as memórias tendem a ser muito mais lentas do que o processador e sua tecnologia não têm avançado tão rapidamente quanto a dos processadores.

Assim, pode-se entender um pouco mais sobre esse sistema e como ele apóia o trabalho dos processadores em busca de sistemas cada vez mais eficientes.



Hierarquia de Memória

Em todo sistema computacional, a memória é componente essencial e de extrema relevância para o bom funcionamento do computador. Com o passar dos anos, as memórias evoluíram e são formadas por vários componentes numa chamada Hierarquia de Memória.

Na Figura, Hierarquia de Memória é apresentada como o ela é organizada. As memórias de mais velozes possuem custo por bit maior, devido às suas tecnologias, mais avançadas e mais complexas para fabricação.

As tecnologias mais avançadas até o momento são as chamadas SRAM Static Random-Access Memory.

Elas são mais utilizadas em registradores e memórias Cache. Por serem mais caras, elas estão presentes nos computadores em quantidades menores, para não encarecer demais o

projeto. Já a memória principal é fabricada utilizando tecnologia DRAM Dynamic Random-Access Memory. Por serem de tecnologia menos sofisticada, são mais lentas, mas mais baratas do que as SRAM. Por isso elas são montadas em maior quantidade do que as memórias Cache e os registradores.

Já as Memórias Secundárias são formadas por tecnologias de memórias Magnéticas e Ópticas. Suas principais características são o baixo preço por bit, baixo preço e, por consequência, alta capacidade. Além disso, as Memórias Secundárias são memórias não voláteis, ou seja, seus conteúdos são preservados mesmo com a interrupção da fonte de energia. Devido ao avanço da complexidade das memórias dos computadores, elas são organizadas formando o chamado Sistema de Memória.

Em sistemas computacionais o Sistema de Memória se baseia no Princípio da Localidade, que se divide em Temporal e Espacial.

- O Princípio da Localidade Temporal: diz que um dado acessado recentemente tem mais chances de ser usado novamente, do que um usado há mais tempo. Isso é verdade porque as variáveis de um programa tendem a ser acessadas várias vezes durante a execução de um programa, e as instruções usam bastante comandos de repetição e subprogramas, o que faz instruções serem acessadas repetidamente. Sendo assim, o Sistema de Memória tende a manter os dados e instruções recentemente acessados no topo da Hierarquia de Memória.
- O Princípio da Localidade Espacial: diz que há uma probabilidade de acesso maior para dados e instruções em endereços próximos àqueles acessados recentemente. Isso também é verdade porque os programas são sequenciais e usam de repetições. Sendo assim, quando uma instrução é acessada, a instrução com maior probabilidade de ser executada em seguida, é a instrução logo a seguir dela. Para as variáveis o princípio é semelhante. Variáveis de um mesmo programa são armazenadas próximas umas às outras, e vetores e matrizes são armazenados em sequência de acordo com seus índices. Baseado neste princípio, o Sistema de Memória tende a manter dados e instruções próximos aos que estão sendo executados no topo da Hierarquia de Memória.

O ponto inicial da memória é a Memória Principal. Todo programa para ser executado deve ser armazenado nesta memória, com todos seus dados e instruções.

Com base no Princípio da Localidade, sempre que o processador solicita um dado/instrução da memória, ele e seus vizinhos (Localidade Espacial) são copiados para a Memória Cache no nível superior a seguir da hierarquia, Cache L2, por exemplo. Uma parte menor deste bloco é transferida para o nível seguinte (Cache L1, por exemplo), e uma parte ainda menor (porções individuais) é transferida para registradores.

Quando o processador vai acessar um endereço de memória, ele faz uma consulta no sentido inverso, do topo da hierarquia até a base. Primeiro ele busca o conteúdo nos registradores. Se não encontrar, ele vai buscar no primeiro nível de Cache. Se não encontrar, ele busca no próximo nível de Cache e, por fim, na Memória Principal.

Memórias de Semicondutores

As memórias de semicondutores são consideradas aquelas que utilizam composição de transistores como forma principal de armazenamento.

Dentro deste grupo estão os registradores, memórias cache, memórias principais e, mais recentemente, cartões de memória, pen drives e os chamados Dispositivos de Estado Sólido (SSD), que não possuem formatos de disco, mas receberam esse nome por serem os candidatos mais cotados a substituírem os Discos Rígidos HD.

Dentro das memórias de semicondutores tem-se:

- Random Access Memory RAM
- Dynamic RAM DRAM
- Static RAM SRAM
- Synchronous Dynamic RAM SDRAM
- Double-Data Rate SDRAM DDR-DRAM

• Read Only Memory - ROM

Random Access Memory - RAM

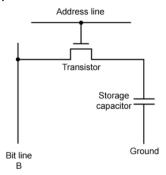
O termo Random Access Memory, ou RAM, ou Memória de Acesso Aleatório em português, veio porque essa tecnologia substituiu as anteriores memórias de Acesso Sequencial. No Acesso Sequencial, os endereços são acessados obrigatoriamente de forma sequencial, 0, 1, 2, 3,... Essa é a forma de acesso de memórias magnéticas, como fitas cassete e VHS..

As memórias de acesso aleatório podem acessar qualquer endereço diretamente, independentemente de sua posição.

O termo Memória RAM é utilizado de forma errada para representar a Memória Principal, mas na verdade, tanto registradores, quanto memória Cache e Memória Principal são feitas utilizando tecnologia RAM. Assim, RAM é uma tecnologia e não uma memória. A partir de hoje então, não utilize mais memória RAM, mas Memória Principal quando se referir à principal memória dos computadores.

Dynamic RAM - DRAM

As memórias Dynamic RAM são as mais simples de serem fabricadas. Como mostrado na figura, é formada simplesmente por um único transistor e um capacitor.



DRAM – Circuito Elétrico

A figura acima uma memória de um único bit. O transistor cuida de abrir ou fechar a passagem de corrente para linha B. Já a linha de endereço é utilizada para fechar a porta do transistor e carregar o capacitor. Se o capacitor estiver carregado, é considerado que a memória contém o bit 1. Caso contrário, a memória contém o bit 0.

A simplicidade da implementação traz resultado no seu principal ponto negativo. O capacitor responsável por manter a carga da memória só é capaz de manter a carga por um curto tempo. Aos poucos, a carga vai sendo dissipada, até o momento em que era o bit 1, se torna 0, gerando um erro. Para evitar isso, é adicionado um circuito a parte que de lê o conteúdo da memória periodicamente e recarrega todos capacitores que estão com bit 1.

As memórias atualmente estão na casa dos Giga Bytes. Ou seja, bilhões de bytes. Então, bilhões de capacitores devem ser lidos e recarregados periodicamente para que os conteúdos não sejam perdidos. Esta técnica é chamada de Refrescamento. Ela resolve o problema dos dados perdidos, mas atrapalha bastante o desempenho da memória. Sempre que a Refrescamento precisa ser realizada, todo acesso é bloqueado. Nada pode ser lido ou escrito enquanto isso. Assim, o processador precisa esperar que o processo de refrescarem termine para poder acessar novamente a memória.

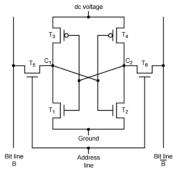
Devido à sua simplicidade de fabricação, as memórias DRAM são mais utilizadas para compor a Memória Principal, devido ao preço mais acessível do que das modernas SRAM.

Static RAM - SRAM

As memórias RAM Estáticas, Static RAM ou SRAM, se baseiam na composição de transistores para que a carga para manter o bit 1 e compartilhada entre outros transistores.

As memórias SRAM não precisam de circuito de refresh, por isso, não precisam parar e tornam-se muito mais rápidas do que as DRAM. O problema é que elas precisam de muito mais transistores por bit, o que torna o projeto maior e, por consequência, mais caro.

Devido ao seu preço, elas são mais utilizadas em memórias Cache, mas em menor quantidade do que as memórias principais.



SRAM - Circuito Elétrico

A ilustração acima à direita, apresenta a composição de transistores, o transistor T5 é que determina se o bit é 0 ou 1, e os transistores, T1 e T3 são utilizados para recarregá-lo, caso sua carga reduza. Já os transistores T2, T4 e T6 são o complemento deles de forma inversa, adicionando um nível a mais de segurança. Essa técnica é chamada Complementary MOS - CMOS.

Synchronous Dynamic RAM - SDRAM

Já a Synchronous Dynamic RAM (SDRAM) é uma DRAM com um simples avanço. O relógio que determina o tempo das SDRAM vem diretamente do processador, e não de um relógio próprio, como nas DRAM convencionais. Isso faz com que o momento exato do Refrescamento seja determinado pelo processador.

Dessa forma, o processador sabe exatamente quando ele não pode acessar a memória, e dedica seu tempo às outras tarefas, ou seja, o processador não perde mais tanto tempo esperando a memória.

Double-Data Rate SDRAM - DDR-RAM

Após as SDRAM surgiram as DDR-SDRAM. As memórias DDR são síncronas como as SDRAM, mas elas possuem um barramento extra que faz com que, a cada ciclo de clock da memória, o dobro de dados é transferido. As memórias DDR e suas sucessoras (DDR2, DDR3, DDR4, DDR5) são mais utilizadas para utilização como memória principal.

Read-Only Memory - ROM

As memórias ROM também possuem um nome criado há muitos anos e hoje é um termo que não faz tanto sentido. Em português significam Memória Apenas de Leitura. Isso porque as primeiras ROM eram escritas durante a fabricação e não podiam mais ser modificadas. Mas outras gerações foram desenvolvidas que permitiram à escrita e tornou o termo ROM antiquado.

Todas as memórias ROM são não voláteis, ou seja, mantêm seu conteúdo mesmo com a falta do fornecimento de energia elétrica. São tipos de memória ROM:

- PROM: As memórias PROM Programmable ROM são memórias que vem com as conexões abertas de fábrica e precisam de uma máquina para que os dados sejam escritos nelas. Uma vez escritos, eles não podem mais ser modificados.
- EPROM: As memórias EPROM Erasable PROM se baseiam no mesmo princípio das PROM, mas uma máquina especial que utiliza raios UV pode ser utilizada para apagar todo seu conteúdo e escrever novamente.
- **EEPROM**: As memórias EEPROM Electronically Erasable PROM possuem o mesmo princípio das PROM, mas a máquina utilizada para escrita e apagar é eletrônica. Isso permite que um computador, ou uma máquina especial seja utilizado para escrever nas memórias, as tornando muito mais utilizadas.
- **Flash**: As memórias Flash se baseiam no princípio das memórias EEPROM, mas o processo de apagar é feito em blocos grandes, o que acelera bastante o processo.

As memórias ROM são muito usadas na formação da BIOS e as memórias Flash são o princípio básico de cartões de memória, pen drives e memórias de estado sólido.

Memórias Secundárias

As memórias que vimos até o momento são chamadas de Memórias Primárias, porque são ligadas na própria placa-mãe **e** usadas para o funcionamento básico e primário da CPU. Já

as memórias secundárias são utilizadas para dar um suporte a mais ao sistema, ampliando sua capacidade de armazenamento e ligadas por interfaces próprias.

São as principais tecnologias utilizadas como memórias secundárias:

- Memórias magnéticas
- Memórias ópticas
- Memórias de estado sólido

As memórias magnéticas utilizam o princípio de polarização para identificar dados numa superfície magnetizável. Assim com gravação magnética as áreas da memória são polarizadas como polo positivo ou negativo. Quando a região é polarizada com polo positivo, dizemos que ela armazena o bit 1, e armazena o bit 0, quando a polarização for negativa. O maior exemplo de memória magnética utilizado hoje são os Discos Rígidos, ou do inglês Hard Disk ou HD.

Já as memórias ópticas armazenam seus dados numa superfície reflexiva. Para leitura, um feixe de luz (LASER) é disparado contra um também minúsculo ponto. O feixe bate na superfície volta para um sensor. Isso indicará que naquele ponto há o bit 0. Para armazenar o bit 1, outro LASER entra em ação provocando uma pequena baixa na região. Com isso, ao fazer uma leitura no mesmo ponto, o feixe de luz ao bater na superfície com a baixa será refletido, mas tomará trajetória diferente, atingindo outro sensor diferente daquele que indicou o bit 0. Quando este segundo sensor detecta o feixe de luz, é dito que o bit lido foi o 1. O maior representante das memórias ópticas são os CDs, DVDs e, mais recentemente os Blu Ray.

As memórias de estado sólido ou Solid State Drive - SSD são memórias feitas com tecnologia Flash, mas para ser usadas em substituição ao Disco Rígido. Em comparação com ele, a memória de estado sólido é muito mais rápida, mais resistente a choques e consome menos energia. Porém, as memórias de estado sólido são bem mais caras.

Memória Virtual

Com o crescente aumento da quantidade e tamanho dos programas sendo executados pelos processadores, surgiu a necessidade de cada vez mais memória principal. Ao mesmo tempo, quando há muitos programas sendo executados ao mesmo tempo, há uma grande tendência de haver muitos deles esquecidos, sem serem acessados. Esses programas ocupam espaço da memória principal de forma desnecessária.

Pensando nisso, foi criado o conceito de Memória Virtual, que nada mais é do que a técnica de utilizar a Memória Secundária, geralmente HD ou SSD, como uma extensão da Memória Principal. Desta forma, quando a memória principal está cheia e não há mais espaço para novos programas ou dados, o sistema utiliza a memória secundária.

Tudo é feito de forma automática pela Unidade de Gerência de Memória (ou Memory Management Unit - MMU) presente nos processadores. Assim, todo dado que é acessado é antes buscado pela MMU na memória principal. Se ele não estiver lá, ela vai buscar na memória secundária, faz uma cópia na memória principal e libera o acesso ao dado.

A principal técnica de Memória Virtual é a Paginação. Na Paginação, todos os dados são acessados através de páginas. Isso facilita o processo de organização e localização dos dados que estão na memória principal e secundária. Agora, ao invés de gerenciar palavra por palavra, o sistema gerencia grandes blocos (geralmente de 64KB) chamados de páginas.

Memória Cache

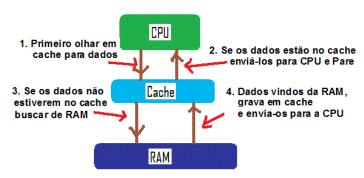
As memórias Cache vem tendo um papel cada vez mais importante nos sistemas computacionais. Inicialmente elas nem existiam nos computadores. Depois foram adicionadas fora do processador e em pequena quantidade. Em seguida elas foram levadas para dentro do processador e hoje em dia ocupam entre 60% e 80% da área do chip do processador.

O princípio básico da memória Cache é o de manter uma cópia dos dados e instruções mais utilizados recentemente (Princípio da Localidade) para que os mesmos não precisem ser buscados na memória principal. Como elas são muito mais rápidas do que a memória principal, isso traz um alto ganho de desempenho.

Todo dado a ser lido ou escrito em memória (vide figura abaixo) pelo processador antes passa para a Cache. Se o dado estiver na Cache, a operação é feita nela sem acesso a Mem. Principal. Caso contrário, um bloco inteiro de dados (geralmente com 4 palavras de memória) é trazido da Mem. Principal e salvo na Cache. Só então a CPU realiza a tarefa com o dado.

Sendo assim, o desempenho do computador ao acessar um dado de memória é probabilístico. Para cada dado a ser acessado há uma probabilidade de ele estar na memória Cache. Se isso ocorrer é dito que houve um Cache Hit e o sistema ganha muito tempo com isso. Caso contrário, ocorre uma Cache Miss e o desempenho é bastante prejudicado.

Então a questão é como se faz para aumentar a probabilidade de um determinado dado estar na Cache ao invés da Memória Principal? Pode-se também refazer esta pergunta de uma forma mais geral. Como aumentar a taxa de Cache Hit ou diminuir a taxa de Cache Miss?



Estrutura de uma SRAM

Há 3 principais estratégias para isso:

- Aumentar o tamanho da Memória Cache
- Mudar a função de mapeamento
- Mudar a política de substituição

Tamanho

A grande dificuldade das memórias Cache é que elas sempre estão presentes em menor quantidade do que a Memória Principal. Em geral a Cache de um computador é 1.000 vezes menor do que a Memória Principal. Um computador com 4GB de Memória Principal, terá muita sorte se o processador tiver 4MB de Memória Cache.

Como a Memória Cache trabalha armazenando cópias de dados da Memória Principal, quanto maior for a Memória Cache, mais dados ela é capaz de armazenar, sendo assim, maior a probabilidade de o processador buscar por um dado e ele estar na Cache. Entretanto, é importante observar que esse crescimento não é constante, muito menos infinito. Veremos a seguir que o ganho de desempenho com o aumento do tamanho do Cache possui um limite.

Função de mapeamento

A função de mapeamento diz respeito a estratégia utilizada para determinar onde cada dado da memória principal estará na Cache. Ela determina onde cada dado da Memória Principal será copiado na Cache caso ele seja acessado. Isso é muito importante porque o processador vai seguir essa mesma estratégia para conseguir localizar se o dado está ou não na Cache. Há três tipos de mapeamento: Mapeamento Direto; Mapeamento Associativo e Mapeamento Associativo por Conjunto

Mapeamento Direto

Para entendermos a diferença entre os tipos de mapeamento, vamos fazer uma analogia com uma sala de cinema. Imagine que o cinema é a Memória Cache e cada pessoa é um dado a ser armazenado na memória. No mapeamento direto cada pessoa (sócia daquele cinema) receberá uma cadeira dedicada a ele. Sempre que ele for ao cinema, deverá sentar no mesmo lugar.

O problema é que a Memória Principal é muito maior do que a Memória Cache, então não há cadeira para todos. Para resolver, cada cadeira é distribuída por várias pessoas, apostando que nem sempre as pessoas que compartilham o mesmo número de cadeira irão assistir ao mesmo filme no mesmo horário. Mas quando isso acontece, a pessoa que chegou por último não pode sentar em outra cadeira mesmo estando livre. A pessoa que chega depois toma o lugar da pessoa que está sentada, porque no caso da memória Cache, o último sempre tem preferência. Imagine quanta confusão isso geraria nesse cinema!

O bom do mapeamento direto é porque ele é muito fácil de organizar e a CPU encontra sempre seu dado muito facilmente.

No exemplo do cinema, se alguém estiver querendo saber se uma pessoa está no cinema (na Cache) ou não (na Memória Principal) basta saber o número da cadeira dele e ir lá verificar se é ele quem está sentado. Isso acelera bastante o trabalho de busca da CPU. Mas se a Cache for muito menor que a Principal, haverá muitos blocos com mesmo código e pode haver muito conflito de posição, reduzindo o desempenho.

Mapeamento Associativo

No mapeamento associativo, o mecanismo de alocação de blocos da Memória Principal na Cache não segue posição fixa. Cada bloco vai ocupar a primeira posição vazia encontrada. Voltando ao exemplo do cinema, seria uma sala sem cadeira reservada, mas com um porém.

Se uma pessoa chegar e o cinema estiver cheio, a direção do cinema (no computador é o Sistema de Memória) vai escolher uma pessoa a ser removida para dar lugar a nova pessoa que chegou (talvez alguém que estiver dormindo ou conversando durante o filme).

O mapeamento associativo termina sendo mais eficiente do que o mapeamento direto no momento de alocar blocos da memória na Cache. Só haverá espaço inutilizado se não houver acesso suficiente à Memória Principal.

A desvantagem deste tipo de mapeamento está no momento de buscar um bloco na Cache. Imagine agora que alguém chegue ao cinema cheio a procura de uma pessoa. Como encontrá-la? Deve-se percorrer todas cadeiras verificando se a pessoa está em alguma delas.

Para o sistema computacional, a busca é custosa o que resulta na utilização deste mapeamento apenas se a Cache não for grande demais.

Mapeamento Associativo por Conjunto

O problema do Mapeamento Associativo é encontrar blocos em memórias Cache grandes. A solução para isso é utilizar uma abordagem mista, que utiliza os princípios dos mapeamentos direto e associativo.

Ela divide a memória em conjuntos. Cada bloco então é mapeado para um conjunto (semelhante ao que é feito para o Mapeamento Direto, mas para o nível de conjunto). Sempre que um bloco for ser buscado ou salvo, ele será feito no conjunto fixo dele, mas dentro do conjunto ele pode ser armazenado em qualquer posição livre.

Voltando ao cinema, é como se uma grande sala fosse dividida em salas menores. Cada pessoa teria no seu ingresso o número da sala, mas a poltrona seria escolhida livremente. Escolhendo a quantidade certa e o tamanho das salas, é possível utilizar bem os espaços e facilitar o processo de busca por uma pessoa.

Política de substituição

Nos mapeamentos associativo e associativo por conjunto outra política deve ser adotada. Quando a cache enche e um novo bloco precisa ser armazenado, o Sistema de Memória deve escolher que bloco deve ser removido para dar espaço ao novo bloco. No mapeamento direto isso não existe porque cada bloco sempre fica na mesma posição.

Sendo assim, há 3 principais políticas de substituição de linhas de Cache. São elas:

- Randômica: Na substituição randômica o sistema escolhe aleatoriamente o bloco que deve ser removido. Ele sai da Cache dando lugar ao novo bloco que foi acessado. Este método tem a vantagem de ser muito fácil de implementar e, por consequência, rápido de executar. Porém ele pode não ser muito eficiente.
- **FIFO**: No FIFO First-In First-Out adota o princípio de fila. O bloco que chegou 1º está a mais tempo na Cache. Já se beneficiou e deve então dar lugar ao novo bloco.
- LRU: No LRU Least-Recently Used ou Menos Usado Recentemente aplica o Princípio da Localidade Temporal e torna-se por isso mais eficiente na maioria dos casos. Nesta política o sistema escolhe o bloco que menos foi utilizado recentemente e o remove. Isso faz com que fiquem na Cache aqueles blocos que são acessados mais vezes nos últimos instantes.

Cache

Quando se carrega programas ou arquivos a partir de um HD, o dispositivo deve pesquisar internamente a informação, em seguida transfere para RAM o seguimento encontrado. No entanto, o HD é o dispositivo de armazenamento mais lento no computador.

Normalmente é considerado a RAM como sendo muito rápido, porque é muito mais rápido do que os discos rígidos. A RAM é uma área de armazenamento temporário que fica ativa quando o computador inicializa. Computadores têm de 1 a 16GB de RAM. Ao se carregar programas mais solicitados (arquivos, fotos e outros itens) para a RAM, o computador não tem que pesquisar o HD para obter as informações sobre os pedidos posteriores.

A atuação do Cache de memória é extremamente rápida se for construído nos microprocessadores ou localizado próximo a ele em um chip separado. A CPU usa cache de memória para armazenar instruções que são repetidamente necessários para executar programas, melhorando a velocidade geral do sistema.

O trabalho de cache da CPU é antecipar os pedidos de dados, de modo que quando o usuário clica em um programa usado com frequência, por exemplo, as instruções necessárias para executar esse programa estão prontos, armazenada em cache. Quando isso acontecer, a CPU pode processar o pedido sem demora e melhorar o desempenho do computador.

Deve-se considerar que a CPU pode trabalhar mais rápido do que a RAM, e para acelerar as coisas, foi criado e construído caches em até 3 níveis: L1, L2 e L3, de forma a atuar como *intermediários* que antecipam quais solicitações serão feitas de RAM, armazenando os dados. Quando chega um pedido, a CPU verifica cache L1 em primeiro lugar, seguido por L2 e L3 cache (se presente). Se a CPU encontra os dados solicitados no cache, que é um *cache hit*, e se não for, é um *erro de cache* e a memória RAM é pesquisado próximo, seguido pelo HD.

O projeto da cache é estratégico no mercado de microprocessadores altamente competitivo, uma vez que é diretamente responsável pela melhoria da CPU e desempenho do sistema. Cache de Multinível é feita a partir de mais caras SRAM. Lembrando que DRAM e SDRAM são o que normalmente se referem simplesmente como RAM.

Ao se observar os novos computadores geralmente não são dispostos os valores de cache L1, L2 e L3. O resto é tudo igual, mas um sistema com mais cache na CPU terá melhor desempenho, e o cache síncrono é mais rápido que assíncrona.

O cachê L1

Nível 1 ou cache L1 é uma memória (registrador) especial, muito rápido construído na unidade de processamento central para melhorar o desempenho do computador. Ao carregar os bits usados com frequência de dados em cache L1, o computador pode processar os pedidos mais rapidamente. A maioria dos computadores também tem cachê L2 e L3 que são mais lentos que o cache L1, mas mais rápido do que a RAM.

Atualmente o cache L1 é construído na CPUs. O cache L2 pode ser integrado à CPU ou presente na placa-mãe, junto com cache L3. Em alguns casos a cache L3 também está sendo incorporada no CPU. Ao contrário da RAM, cache não é expansível.

O Cachê L2

Cache L2 faz parte de uma estratégia de armazenamento multinível para melhorar o desempenho do computador. Enquanto a, cache L1 que é mais frequentemente integrado à CPU, a cache L2 tipicamente é construída na placa-mãe (junto a cache L3, quando presente).

O processador verifica cache L1, seguido por L2 e L3 cache. Se ele encontrar os bits necessários de dados, este é um *acerto de cache*, mas se o cache não antecipar o pedido, a CPU recebe um *erro de cache*, e os dados devem ser buscados na RAM que é mais lenta ou a unidade de HD que é mais lento ainda. Considerações: Uma vez que é o trabalho da cache para CPU é armazenar dados, pode-se perguntar por que há mais de um nível de cache.

Por que ter cache L2 em tudo, muito menos L3, se pode apenas fazer cache L1 maior?

A resposta, quanto maior o cache, mais tempo a latência. Pequenas caches são mais rápidas do que as grandes. Para otimizar o desempenho geral, o melhor resultado é obtido com o menor, mais rápida e imediata para a própria CPU, seguido de uma memória um pouco maior cache L2, e uma memória ainda maior de cache L3.

A ideia é manter instruções usadas com mais frequência em L1, com cache L2 os bits mais prováveis necessários próximos de dados e L3 seguir o exemplo. Se a CPU processar uma solicitação que não está no cache L1, verifica de modo rápido nas caches L2, L3.

O Cachê L3

Cache L3 é especializada na memória que trabalha lado a lado com a cache L1 e L2 para melhorar o desempenho do computador. Os caches L1, L2 e L3 são ligados ao processamento inerente à CPU, há outros caches no sistema computacional, tais como cache de HD, o cache da CPU atende às necessidades do microprocessador, antecipando as solicitações de dados para que as instruções de processamento sejam fornecidas sem demora.

O cache da CPU é mais rápido do que da RAM, e é projetado para evitar gargalos no desempenho. Assumindo que as instruções necessárias são encontradas em cache L3 (uma cache hit), bits de dados podem ser despejados de cache L1 para manter as novas instruções, caso eles sejam necessários novamente.

Cache L3 pode então remover essa linha de instruções, uma vez que agora reside em outro cache (cache como referido *exclusivo*), ou pode ficar com uma cópia (conhecida como cache *inclusive*), dependendo do projeto da CPU.

Coerência de Cache

Coerência de cache é o problema natural que ocorre quando conjunto de dados de um sistema é acessado e alterado por vários agentes. É a principal área de arquitetura de computadores, isso se torna um problema é em computadores com múltiplos processadores. Cada processador em um computador multiprocessador tem seu próprio cache que carrega e armazena as informações da RAM. Quando 2 processadores estão acessando a mesma área de memória, coerência de cache seria perdida se certas precauções não foram tomadas.

Sem coerência de cache, um sistema multiprocessador seria incapaz de funcionar. Existem vários métodos que foram desenvolvidos, a fim de resolver esta questão e evitar possíveis problemas. Coerência baseado em diretório, monitoramento espionagem (snarfing) são três métodos utilizados para evitar a perda de coerência de cache.

Tipos de encapsulamento de memória

O encapsulamento correspondente ao artefato que dá forma física aos chips de memória. Descrição e evolução dos tipos de encapsulamento mais utilizados pela indústria:

DIP (Dual In-line Package): um dos primeiros tipos de encapsulamento utilizado em memórias, sendo especialmente popular nas épocas dos computadores XT e 286. Como possui terminais de contato, *perninhas*, de grande espessura, seu encaixe ou mesmo sua colagem através de solda em placas, pode ser feita facilmente de forma manual;

SOJ (Small Outline J-Lead): esse encapsulamento recebe este nome porque seus terminais de contato lembram a letra 'J'. Foi bastante utilizado em módulos SIMM (vistos mais à frente) e sua forma de fixação em placas é feita através de solda, não requerendo furos na superfície do dispositivo;

TSOP (Thin Small Outline Package): tipo de encapsulamento com espessura reduzida em relação aos padrões anteriores (cerca de 1/3 menor que o SOJ). Por conta disso, seus terminais de contato são menores, além de mais finos, reduzindo a incidência de interferência na comunicação. É aplicado em SDRAM e DDR Há uma variação desse encapsulamento, **STSOP** (Shrink Thin Small Outline Package) ainda mais fino;







CSP (Chip Scale Package): mais recente, o encapsulamento CSP se destaca por ser "fino" e por não utilizar pinos de contato que lembram as tradicionais "perninhas". Ao invés disso, utiliza um tipo de encaixe chamado **BGA** (Ball Grid Array). Esse tipo é utilizado em módulos como DDR2 e DDR3 (que serão vistos à frente).



Módulos de memória

O *módulo* ou, ainda, *pente* de memória, uma pequena placa onde são instalados os encapsulamentos de memória. Essa placa é encaixada na placa-mãe por meio de encaixes (*slots*) específicos para isso. Eis uma breve descrição dos tipos mais comuns de módulos:

- **SIPP** (Single In-Line Pins Package): é um dos primeiros tipos de módulos que chegaram ao mercado. É formato por chips com encapsulamento DIP. Em geral, esses módulos eram soldados na placa-mãe;
- SIMM (Single In-Line Memory Module): módulos deste tipo não eram soldados, mas encaixados na placa-mãe. A 1ª versão com 30 pinos de contato (SIMM de 30 vias) e era formada por um conjunto de 8 chips (ou 9, para paridade). Com isso, podiam transferir um byte por ciclo de *clock*. Em seguida surgiu versão com 72 pinos (SIMM de 72 vias), maior e capaz de transferir 32 bits por vez. Módulos SIMM de 30 vias tinham capacidades de 1MB a 16MB. Módulos SIMM de 72 vias, eram encontrados com capacidades que iam de 4MB a 64MB. Em geral tempo de acesso de 70ηs;
- DIMM (Double In-Line Memory Module): os módulos DIMM nomeados por terem contatos em ambos os lados do pente. Transmitiam 64 bits por vez. A 1ª versão, aplicada em memória SDR SDRAM, tinha 168 pinos. Logo vieram módulos de 184 vias, utilizados em DDR, e módulos de 240 vias, utilizados em módulos DDR2 e DDR3. Existe um padrão DIMM de tamanho reduzido chamado SODIMM (Small Outline DIMM), para notebooks, módulos SODIMM de 72 e 144 pinos ou vias;
- **RIMM** (Rambus In-Line Memory Module): formado por 168 vias, o módulo era utilizado nas memórias Rambus. Requeria para cada pente de memória Rambus instalado no computador é necessário instalar um módulo "vazio", de 184 vias, chamado de **C-RIMM** (Continuity-RIMM).

Tecnologias de Memórias

Várias tecnologias de memórias foram desenvolvidas com o tempo. Neste sentido se apresentam como memórias mais rápidas, com maior capacidade e até memórias que exigem cada vez menos energia. Principais tipos de memória RAM:

FPM (Fast-Page Mode): Memória assíncrona foi uma das primeiras tecnologias de memória RAM. A primeira leitura tem um tempo de acesso maior que as leituras seguintes. Isso porque são feitos, na verdade, quatro operações de leitura seguidas, ao invés de apenas uma, em um esquema do tipo x-y-y-y, por exemplo: 3-2-2-2 ou 6-3-3-3. A 1ª leitura acaba sendo mais demorada, mas as 3 seguintes são mais rápidas. Isso porque o controlador de memória trabalha apenas uma vez com o endereço de uma linha (RAS) e, em seguida, trabalha com uma sequência de quatro colunas (CAS), ao invés de trabalhar com um sinal de RAS e um de CAS para cada bit. Memórias FPM utilizavam módulos SIMM, tanto de 30 quanto de 72 vias;

EDO (Extended Data Output): Memória Assíncrona possuía como destaque a capacidade de permitir que um endereço da memória fosse acessado ao mesmo tempo em que uma solicitação anterior ainda em andamento. Foi aplicado módulo SIMM, e também foi encontrado nos módulos DIMM de 168 vias. Houve uma tecnologia semelhante, chamada **BEDO** (Burst EDO), possuía tempo de acesso menor foi pouco utilizada, tinha custo maior e de propriedade da empresa Micron. Foi superada pela introdução da tecnologia SDRAM;



Módulo de memória EDO

SDRAM (Synchronous Dynamic Random Access Memory): As SDRAM trabalhavam sincronizadas com o processador sem *delay*. A partir dessa tecnologia, passou-se a considerar a frequência que a memória trabalha para medida de velocidade. Surgiam então as memórias **SDR SDRAM** (Single Data Rate SDRAM), que podiam trabalhar com 66 MHz, 100 MHz e 133 MHz (também chamadas de PC66, PC100 e PC133, respectivamente). Muitas pessoas se referem a essa memória apenas como memórias SDRAM ou, ainda, como memórias DIMM, por causa de seu módulo. A denominação SDR é a mais adequada;



Módulo de memória SDR SDRAM (há duas divisões entre os terminais)

DDR SDRAM (Double Data Rate SDRAM): as memórias DDR apresentam evolução significativa em relação ao padrão SDR, isso porque elas são capazes de lidar com o dobro de dados em cada ciclo de *clock*. A DDR que trabalha à frequência de 100 MHz acaba dobrando seu desempenho, como se fosse à taxa de 200 MHz;



DDR2 SDRAM: como o nome indica, as memórias DDR2 são uma evolução das memórias DDR. Principal característica era a capacidade de trabalhar com quatro operações por ciclo de *clock*, portanto, o dobro do padrão anterior. Os módulos DDR2 também contam com apenas uma divisão em sua parte inferior, no entanto, essa abertura é um pouco mais deslocada para o lado.



DDR3 SDRAM: As memórias DDR3 outra evolução. Novamente, aqui se dobra a quantidade de operações por ciclo de *clock*, desta vez, de oito, procedimentos de leitura ou gravação a cada ciclo de *clock*, quatro no início deste e outros quatro no final.



Um aspecto onde a memória DDR3 leva desvantagem: a latência, em poucas palavras, o tempo que a memória leva para fornecer um dado solicitado. Quanto menor esse número, melhor. Eis as taxas mais comuns para cada tipo de memória:

- **DDR**: 2, 2,5 e 3 ciclos de clock;
- DDR2: 3, 4 e 5 ciclos de clock;
- DDR3: 6, 7, 8 ou 9 ciclos de clock.

Memória	Nome do	Frequência	Frequência	Taxa de
	Módulo	Interna	Externa	Transmissão
DDR3-800	PC3-6400	100 MHz	400 MHz	6.400 MBps
DDR3-1066	PC3-8500	133 MHz	533 MHz	8.533 MBps
DDR3-1333	PC3-10600	166 MHz	667 MHz	10.667 MBps
DDR3-1600	PC3-12800	200 MHz	800 MHz	10.800 MBps
DDR3-2000	PC3-16000	250 MHz	1000 MHz	16.000 MBps
DDR3-2133	PC3-17000	266 MHz	1066 MHz	17.066 MBps
DDR3-2400	PC3-19200	300 MHz	1200 MHz	19.200 MBps
DDR3-2600	PC3-20800	326 MHz	1300 MHz	20.800 MBps
DDR3-2800	PC3-22400	350 MHz	1400 MHz	22.400 MBps

Memória DDR4

As memórias do tipo DDR4 ainda não são tão comuns, mas, aos poucos, vão ganhando popularidade. No geral, elas prometem uma maior largura de banda do que as DDR3, sendo hoje uma das melhores escolhas para quem pretende montar uma máquina de alto desempenho. Outra característica está no menor consumo de energia.

A seguir uma lista com algumas das memórias DDR4 disponíveis à venda no Brasil. Lembrando que é preciso ter uma placa-mãe compatível com a nova geração de RAM, já que o padrão de conexão é diferente. Confira.



Modelo da Corsair oferece custo-benefício

Na linha dos módulos mais simples, a Corsair oferece a linha Value Select. O modelo trabalha em 2.133 MHz e também conta com CL 15 (latência). O preço é de cerca de R\$ 130 para a versão de 4 GB



Modelo da Kingston é voltado para quem está com o orçamento apertado.

Modelo mais em conta da Kingston para memórias DDR4, pode ser encontrado por cerca de R\$ 110 com 4 GB de capacidade. O hardware opera em 2.133 MHz, trabalha com CL 15 (latência) e pode ser uma opção para quem busca custo benefício.



Hyper X Fury, da Kingston, chega a 2.666 MHz.

Para quem está disposto a investir um pouco mais, o modelo HyperX Fury, também da Kingston, oferece alguns benefícios extras. O dissipador, que melhora o gerenciamento do calor gerado. Além disso, ela também trabalha em uma latência menor (CL 14). Outra característica interessante é o ajuste automático para a melhor frequência possível - ela vem de fábrica operando em 2.133 MHz, mas pode chegar a 2.666 MHz. O preço em torno de R\$ 130 para a versão com 4 GB.



G.Skill Aegis traz 15-15-15-35-2N de latência.

A G.Skill é uma das marcas mais famosas quando o assunto é memória RAM. Uma das linhas mais simples que a empresa disponibiliza para o consumidor brasileiro é a Aegis. Opera até 2.400 Hz e trabalha com CL 4 (latência). O preço é de cerca de R\$ 200 para a versão com 4 GB.





Modelo da Crucial custa cerca de R\$ 400

A Ballistix da Crucial também é uma das opções para modelos DDR4. Com CL 16 (latência) e 2.400 MHz, o modelo conta com um dissipador de calor integrado. A memória pode ser encontrada por cerca de R\$ 400.



Empresa oferece garantia vitalícia em memória Black Fire. A Logic é uma empresa americana que oferece há pouco tempo no Brasil. A linha Black Fire traz como atributo o dissipador reforçado para melhor controle de temperatura. Opera em 2.400MHz. A empresa oferece a garantia vitalícia para o módulo, com a promessa de troca em até 72 horas. O preço é de cerca de R\$ 160 para a versão com 4 GB.

DDR3 ou DDR4: diferenças e avaliação

A memória RAM é um dos componentes vitais de um computador. Além disso, é um dos que geram mais dúvidas na hora de escolher ou montar um PC novo, devido a grande variedade de modelos e marcas. Para tirar todas as dúvidas, confira tudo sobre os padrões DDR3 e DDR4 e entenda as diferenças.

A DDR3 é uma memória de padrão já estabelecido, enquanto a DDR4 é a evolução da tecnologia. Confira o comparativo e veja qual é a mais adequada para o que está procurando.

A princípio, uma comparação direta entre as especificações dos dois modelos é um pouco difícil, visto que a evolução do padrão não traz um grande salto de desempenho, principalmente para o usuário doméstico.

As memórias DDR4 possuem características superiores ao modelo anterior. Ganhos que, mesmo não ofertando um grande avanço para o uso básico, se destacam a medida que a DDR3 atinge os seus limites.

Assim, a DDR4 é uma opção mais interessante para quem deseja uma máquina capaz de rodar programas e jogos mais pesados, preparada para futuros upgrades.

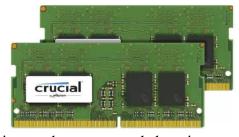




Diferença física do modelo DDR3 e DDR4 da série Dominator Platinum: Divulgação Corsair

Visualmente, os modelos DDR3 e DDR4 apresentam pequenas diferenças. Como a quantidade de pinos de contato e a posição de encaixe. Outro detalhe é que a DDR4 é ligeiramente mais espessa e possui uma leve curva na borda inferior.

Em termos técnicos, os módulos de DDR4 são mais eficientes no quesito energia, utilizando 1,2 volts, enquanto a DDR3 usa 1,5 volts na alimentação. Essa pequena diferença pode gerar uma economiza de até 40% no consumo de energia, o que ajuda a prolongar a vida da bateria para os notebooks, por exemplo.



Memórias DDR4 – econômicas, reduz consumo de bateria em notebook: Divulgação Crucial

Além do baixo consumo, outras vantagens das memórias da nova geração são a capacidade e a frequência de operação. A DDR3 está disponível com capacidades de 512 MB até 8 GB. Já a DDR4, de 4 GB a 16 GB.

Em relação a frequência, a DDR3 trabalha com uma taxa de 800 a 2.400 MHz, enquanto que a DDR4 opera com valores de 2.133 até 4.266 MHz. É uma grande diferença, que permite mais transferências em um mesmo intervalo de tempo.

Em contrapartida, temos um aumento da latência nas memórias DDR4, que é o atraso para a memória iniciar uma leitura. A taxa aumenta conforme a frequência de operação. Nas especificações de uma memória é possível ver esse dado, geralmente indicado como CL10 ou CL11 nas DDR3 e CL14 ou CL15 nas DDR4. Quanto menor o CL, menor é o atraso na leitura.

A taxa de latência é responsável pela pouca diferença de desempenho entre os padrões em comparativos. Por exemplo, dois computadores com configuração de hardware similar, com 8 GB de memória, sendo um DDR3 e o outro DDR4, terão desempenho parecidos. Afinal, apesar do DDR4 operar com uma frequência maior, também tem uma latência maior.



Investir em um sistema DDR4 é para quem roda programas pesados: Divulgação Corsair

Apesar de devagar, o que se deve muito ao alto custo inicial da tecnologia e ao bom desempenho da antecessora, a migração para o uso da DDR4 é uma tendência natural.

Ao se adquirir um novo computador ou fazer um upgrade, PCs que utilizem DDR3 são opções com um custo mais baixo. Porém, com uma vida útil já limitada pela tecnologia, sendo bem provável que nos próximos dois anos ou menos, tenha um equipamento com poucas ou nenhuma opção de melhoria caso opte por um.

Já os que utilizam DDR4, são mais caros. Entretanto, são uma excelente opção para quem quer investir a longo prazo e ter um PC capaz de trabalhar em alta performance e possibilidades de upgrade durante os próximos anos. A configuração é ideal para *gamers* e usuários de programas pesados, como os de modelagem 3D e edição de vídeo.



Memória Kingston HyperX Fury 8GB(2x4GB) DDR4 (a partir de R\$290): Divulgação Kingston

Considerando a existência de computador que usa DDR3, passá-lo para DDR4, será necessário investir nas memórias, e também em uma placa-mãe e um processador compatível.

No Brasil, é possível encontrar diversos modelos de diferentes fabricantes, como Corsair, G.Skill, Crucial e Kingston. A DDR3 tem preço médio de R\$140 com 4 GB e R\$260 de 8 GB. Já a memória DDR4 é vendida por cerca de R\$200 a de 4GB, R\$400 a de 8GB e R\$800 a de 16GB.

Uma dica que serve para ambos os modelos é optar sempre que possível pela memória com menor taxa de latência e maior frequência de operação. Além disso, procure também os kits com pares de memórias, que saem mais em conta do que a individual.

Fontes de pesquisa:

FutureLooks, TechRadar, PCPlus, bit-tech, TechTudo, TecMundo. Livros Didáticos.